

MVP de Engenharia e Análise de Dados: Ecossistema Pix, Dinâmica Regional e Eficácia do MED

Nome: Flávia Teresa de Souza Montalvão

Matrícula: 4052024002136

Disciplina: Engenharia de Dados e Analytics

Ambiente: Databricks Lakehouse Platform (Unity Catalog)

Repositório: GitHub do Projeto - [link](#)

1. Contexto de Negócio e Perguntas (Etapa 2 e 4.1)

1.1 Contexto de Negócio

Desde seu lançamento pelo Banco Central do Brasil (Bacen) em novembro de 2020, o Pix revolucionou o ecossistema financeiro nacional, consolidando-se como o meio de pagamento mais utilizado no país. Contudo, essa rápida adesão trouxe desafios operacionais complexos:

- **Disparidades Regionais:** Diferenças estruturais de liquidez entre os estados e macrorregiões brasileiras, provocando desequilíbrios em liquidações inter-regionais.
- **Segmentação Comportamental:** Diferentes dinâmicas de uso entre Pessoas Físicas (P2P, P2B) e Pessoas Jurídicas (B2P, B2B), influenciadas pelas formas de iniciação (chave estática, QR Code, inserção manual).
- **Segurança e Mecanismos Antifraude:** O aumento das contestações de infração exigiu a criação do Mecanismo Especial de Devolução (MED) pelo Bacen. Compreender a eficácia das devoluções e os reais motivos de bloqueio ou insucesso (como encerramento de conta fraudulenta ou esvaziamento imediato de saldo) tornou-se prioritário para mitigar riscos sistêmicos.

Este projeto tem como objetivo centralizar, enriquecer e modelar transações do Pix, dados demográficos do IBGE e registros de contestações do MED na arquitetura *Medallion* do Databricks, visando fornecer análises gerenciais padronizadas para tomada de decisão.

1.2 Perguntas de Negócio Norteadoras

- **Pergunta 1 (Tendência Temporal):** Como evoluíram mensalmente o volume financeiro, o total de transações e o ticket médio nacional?
- **Pergunta 2 (Assimetria Regional e Renda Per Capita):** Quais macrorregiões concentram o maior montante de liquidação, qual o gasto per capita (ajustado pelo censo IBGE) e quais regiões atuam como emissoras líquidas versus receptoras líquidas de capital?
- **Pergunta 3 (Comportamento Demográfico e Canais):** Quais categorias relacionais (P2P, P2B, B2P, B2B) concentram o maior volume financeiro e qual a distribuição dos canais de iniciação por faixa etária do pagador?
- **Pergunta 4 (Eficácia e Gargalos do MED):** Qual é a eficiência do funil do Mecanismo Especial de Devolução (Contestados -> Aceitos -> Devolvidos) e quais os fatores predominantes para o não ressarcimento de valores fraudados?

1.3 Estrutura dos Dados Brutos (Camada Bronze)

Os dados brutos foram ingeridos em formato Delta a partir de dados públicos do Banco Central e projeções demográficas do IBGE:

1.3.1 Transações Pix (mvp.bronze.raw_pix_transacoes):

- **Fonte Original:** Banco Central do Brasil (Bacen) – [Séries Temporais e Estatísticas de Transações do Pix](#)
- **Descrição:** Registos transacionais agregados mensalmente por rota geográfica, modalidades operacionais e atributos demográficos anonimizados.

Campo na Base Original (Bacen)	Coluna na Camada Raw (Bronze)	Tipo Dado de na Raw	Descrição / Papel no Modelo
Ano/Mês da operação	data_referencia	STRING	Competência temporal da liquidação da transação.
Código IBGE do município pagador	cod_ibge_origem	STRING	Código numérico identificador do município emissor.
Código IBGE do município receptor	cod_ibge_destino	STRING	Código numérico identificador do município de destino.
Tipo de pessoa do pagador	tipo_pessoa_pagador	STRING	Identificação cadastral de Pessoa Física (PF) ou Jurídica (PJ).
Faixa de idade do pagador	faixa_etaria_pagador	STRING	Segmentação etária do ordenante.
Tipo de pessoa do receptor	tipo_pessoa_recebedor	STRING	Identificação de PF ou PJ do beneficiário.
Canal / Meio de iniciação	forma_iniciacao	STRING	Sigla operacional Bacen (DICT, QRDN, MANU, etc.).
Quantidade de operações	quantidade_transacoes	STRING	Contagem total de transferências liquidadas no período.
Montante transacionado (R\$)	valor_total	STRING	Volume financeiro consolidado.

1.3.2 Notificações e Devoluções do MED (mvp.bronze.raw_fraudes_med)

- **Fonte Original:** Banco Central do Brasil (Bacen) – [*Relatórios de Gestão de Fraudes e Resoluções do Mecanismo Especial de Devolução \(MED\)*](#).
- **Descrição:** Relatórios de notificações de infração e resoluções do MED disponibilizados pelo Bacen.

Campo na Base Original (Bacen)	Coluna na Camada Raw (Bronze)	Tipo de Dado na Raw	Descrição / Papel no Modelo
Mês/Ano de referência	mes_ano	STRING	Competência temporal das notificações e apurações.
Quantidade de pedidos abertos	qtd_contestacoes	STRING	Volume de contestações abertas por suspeita de fraude/golpe.
Contestações acatadas	qtd_aceitas	STRING	Volume julgado procedente para estorno pelas instituições.
Devoluções totais efetuadas	qtd_devolvidas_total	STRING	Transações com 100% do saldo devolvido à vítima.
Devoluções parciais efetuadas	qtd_devolvidas_parcial	STRING	Transações com devolução de fração do valor por falta de saldo.
Montante de infrações aceites (R\$)	vlr_contestacoes_aceitas	STRING	Valor total elegível para processo de devolução.
Valor total estornado (R\$)	vlr_devolvido	STRING	Volume financeiro que retornou efetivamente às vítimas.
Perda por ausência de saldo (R\$)	vlr_sem_saldo	STRING	Recursos não recuperados por conta do recebedor esvaziada.
Perda por conta fechada (R\$)	vlr_conta_fechada	STRING	Recursos bloqueados por cancelamento/fechamento prévio da conta.
Perda por outros motivos (R\$)	vlr_outros	STRING	Recursos retidos em razão de outros impedimentos operacionais.

1.3.3 Demografia Municipal e Regional (mvp.bronze.raw_demografia_ibge)

- **Fonte Original:** Instituto Brasileiro de Geografia e Estatística (IBGE) – [Censo Demográfico e Estimativas da População Residente](#).
- **Descrição:** Tabela com código de município, UF, macrorregião brasileira e estimativa populacional recente.

Campo na Base Original (IBGE)	Coluna na Camada Raw (Bronze)	Tipo de Dado na Raw	Descrição / Papel no Modelo
Código de 7 dígitos do município	codigo_ibge	STRING	Chave identificadora única do município.
Nome do município	nome_municipio	STRING	Descrição por extenso do município.
Sigla da Unidade Federativa	sigla_uf	STRING	Sigla do estado brasileiro (ex.: DF, SP, RS).
Nome da macrorregião geográfica	regiao_nome	STRING	Região nacional (Norte, Nordeste, Sudeste, Sul, Centro-Oeste).
População estimada	populacao_estimada	STRING	Total populacional para cálculo de métricas <i>per capita</i> .

1.4 Licença dos Dados

- **Dados de Pagamentos e MED:** Provenientes do Portal de Dados Abertos do Banco Central do Brasil (Bacen), regidos pela Open Database License (ODbL) e pela Política de Dados Abertos do Governo Federal (Decreto nº 8.777/2016).
- **Dados Demográficos:** Disponibilizados pelo Instituto Brasileiro de Geografia e Estatística (IBGE), de domínio público governamental para fins de pesquisa e desenvolvimento.

2. Carga dos Dados (Etapa 4.2)

A importação dos dados para a plataforma Databricks foi implementada em duas etapas:

1. **Recepção dos Arquivos Brutos (Landing Zone):** Os arquivos tabulares (formato JSON) foram descarregados nos Volumes de Armazenamento do Unity Catalog (vide [mvp_engenharia_de_dados/Notebooks/mvp002-download.ipynb](#)).
2. **Carga Bronze com Spark DataFrame API:** Um notebook dedicado lê os arquivos brutos como texto sem mutação (*as-is*), aplicando carimbo de data/hora e o nome do arquivo de origem,


persistindo no formato Delta Lake (vide [mvp_engenharia_de_dados/Notebooks/mvp003-bronze.ipynb](#)).

3. Modelagem e Catálogo de Dados (Etapa 4.3)

O projeto adotou a modelagem dimensional (*Star Schema*) na camada Gold, combinada com a Arquitetura *Medallion* e estruturada sob governança unificada no Unity Catalog dentro do catálogo *mvp*:

Estrutura de Schemas:

- *mvp.bronze*: Tabelas raw(*fraudes_med_raw*, *ibge_populacao*, *ibge_populacao_raw*, *pix_fraudes_med*, *pix_transacoes*, *transacoes_raw*).
- *mvp.silver*: Tabelas limpas e enriquecidas *pix_transacoes*, *fraudes_med* e *ibge_populacao*.
- *mvp.gold*:
 - Dimensões (*dim_tempo*, *dim_regiao*, *dim_perfil_cliente*, *dim_modalidade_pix*);
 - Tabelas Fato (*fato_pix_transacoes*, *fato_pix_fraudes_med*);
 - Visões Analíticas



3.1 Dicionário de Dados do Catálogo Gold (Colunas e Tabelas Principais)

Tabela: **mvp.gold.fato_pix_transacoes** (Principais colunas)

- **sk_tempo** (INT): Chave substituta temporal que relaciona a transação à dimensão de tempo.
- **sk_regiao_pagador** (INT): Chave que identifica a macrorregião/município do pagador na dimensão de região.
- **sk_regiao_recebedor** (INT): Chave que identifica a macrorregião/município de destino na dimensão de região.
- **sk_modalidade** (INT): Chave substituta de ligação à dimensão **dim_modalidade_pix**.
- **quantidade_tx** (BIGINT): Contagem total de transações aprovadas e liquidadas no período.
- **montante_reais** (DECIMAL(18,2)): Montante liquidado em Reais.
- Demais colunas de suporte dimensional, chaves de perfil e metadados de processamento.

The screenshot displays the Snowflake Catalog Explorer interface. On the left, the 'Catalog' sidebar shows the hierarchy: 'Serverless Starter Wareho...' > 'Serverless' > 'ZXS' > 'Catalog' > 'mvp' > 'gold' > 'Tables (18)' > 'fato_pix_transacoes'. The main panel shows the 'Overview' tab for the table 'fato_pix_transacoes'. The description states: 'Fato granular agregada de transações Pix conectada às dimensões do Star Schema'. Below this is a table of columns:

Column	Type	Popularity	Comment	Tags	Column masking
sk_fato_pix	bigint	---			
sk_tempo	int	...			
sk_regiao_pagador	bigint	---			
sk_regiao_recebedor	bigint	---			
sk_perfil_pagador	bigint	---			
sk_perfil_recebedor	bigint	---			
sk_modalidade	bigint	...			
o= anomes	int	...			
data_competencia	date	...			
quantidade_tx	bigint	...			
montante_reais	decimal(1...	...			
ticket_medio_reais	decimal(1...	...			
_gold_processed_at	timestamp	---			

The right sidebar contains additional information about the table:

- About this table:** Owner: flaviomont.trad@gmail.com, Type: Managed, Data source: Delta, Popularity: ...
- Quality:** Not enabled. Data Quality Monitoring is not enabled for this table. [Enable]
- Policies:** [New policy]
- Tags:** [Add tags]
- Row filter:** [Add filter]
- Insights:** Top users: flaviomont.trad@gmail.com. Top joins: mvp.gold.dim_tempo, mvp.gold.dim_regiao, mvp.gold.dim_perfil_cliente, mvp.gold.dim_modalidade_pix, mvp.gold.fato_pix_fraudes_med.
- Related assets:** Visões, mvp_queries, [Analytics] KPI Topo, mvp005-gold, [Analytics] Balanca Inter_Regional, mvp006-analise, ...

Tabela: **mvp.gold.dim_modalidade_pix**

- **sk_modalidade** (INT): Chave primária substituta (*surrogate key*) da dimensão de modalidade.
- **forma_iniciacao** (STRING): Sigla técnica operacional do canal conforme padronização do Bacen (DICT, QRDN, MANU, etc.).
- **forma_iniciacao_desc** (STRING): Descrição semântica legível da forma de iniciação (ex.: *Chave Pix / Manual, QR Code Dinâmico*).
- **ordem_iniciacao** (INT): Chave numérica de ordenação sequencial para exibição consistente em eixos de gráficos e relatórios.
- **natureza** (STRING): Classificação da natureza operacional do fluxo da transação.
- **finalidade** (STRING): Finalidade de negócio associada ao uso da modalidade Pix (ex.: transferência, pagamento, liquidação).
- Demais colunas de suporte analítico e ordenação.

The screenshot displays the Databricks Catalog Explorer for the table **dim_modalidade_pix** in the **mvp.gold** schema. The table is described as "Dimensão das características operacionais da transação Pix com semântica regulatória".

Column	Type	Popularity	Comment	Tags	Column masking
sk_modalidade	bigint	...			
forma_iniciacao	string	...			
forma_iniciacao_desc	string	...			
ordem_iniciacao	int	...			
natureza	string	...			
finalidade	string	...			

Additional details visible in the interface include the table owner (flaviomont.trad@gmail.com), data source (Delta), and a list of related assets such as **mvp.gold.fato_pix_transacoes**.


Tabela: **mvp.gold.fato_pix_fraudes_med**

- **sk_tempo** (INT): Chave substituta temporal da competência da apuração.
- **qtde_pix_contestados** (BIGINT): Quantidade total de notificações de infração abertas por suspeita de fraude/golpe.
- **qtde_contestacoes_aceitas** (BIGINT): Quantidade de notificações deferidas/aceites pelas instituições financeiras.
- **qtde_devolucoes_integrais** (BIGINT): Quantidade de transações com 100% do saldo contestado devolvido à vítima.
- **qtde_devolucoes_parciais** (BIGINT): Quantidade de transações com devolução parcial em razão de insuficiência de fundos.
- **valor_contestacoes_aceitas_reais** (DECIMAL(18,2)): Montante financeiro total julgado procedente para estorno (R\$).
- **valor_devolvido_integral_reais** (DECIMAL(18,2)): Montante financeiro total julgado procedente para estorno (R\$).
- **valor_devolvido_parcial_reais** (DECIMAL(18,2)): Montante devolvido de forma parcial (R\$).

- **valor_nao_devolvido_saldo_insuficiente** (DECIMAL(18,2)): Perda financeira decorrente de conta recebedora sem saldo residual (R\$).
- **valor_nao_devolvido_conta_encerrada** (DECIMAL(18,2)): Perda financeira decorrente do encerramento prévio da conta recebedora (R\$).
- **valor_nao_devolvido_motivos_diversos** (DECIMAL(18,2)): Perda financeira associada a outros impedimentos operacionais (R\$).
- **taxa_efetiva_recuperacao_pct** (DECIMAL(5,2)): Percentual efetivamente recuperado em relação ao total de contestações aceites.
- Demais colunas de detalhamento de devoluções parciais, bloqueios cautelares e metadados operacionais.


The screenshot displays the Databricks Catalog Explorer interface. On the left, a sidebar shows the catalog structure with 'Serverless Starter Warehouse' and 'Serverless' storage. The 'gold' schema is selected, showing a list of tables including 'fato_pix_fraudes_med'. The main panel shows the 'Overview' tab for 'fato_pix_fraudes_med', with a description: 'Fato mensal de fraudes, contestações e devoluções do Mecanismo Especial de Devolução (MED)'. Below this is a table of columns with their types and popularity. The right-hand panel contains metadata such as 'Owner: flaviamont.trad@gmail.com', 'Type: Managed', and 'Data source: Delta'. It also includes sections for 'Quality', 'Policies', 'Tags', 'Row filter', and 'Insights'.

Column	Type	Popularity	Comment	Tags	Column masking
sk_tempo	int	...			
anomes	int	...			
data_competencia	date	...			
qtde_pix_contestados	bigint	...			
qtde_contestacoes_aceitas	bigint	...			
qtde_contestacoes_rejeitadas	bigint	...			
taxa_aceite_por_100k	decimal(1, ...)	...			
qtde_usuarios_marcados_fraude	bigint	...			
qtde_chaves_marcadas_fraude	bigint	...			
valor_contestacoes_aceitas_reais	decimal(1, ...)	...			
qtde_devolucoes_integrais	bigint	...			
valor_devolvido_integral_reais	decimal(1, ...)	...			
qtde_devolucoes_parciais	bigint	...			
valor_devolvido_parcial_reais	decimal(1, ...)	...			
valor_residual_nao_devolvido_r...	decimal(1, ...)	...			
qtde_nao_devolvida_saldo_lhsu...	bigint	...			
valor_nao_devolvido_saldo_lhs...	decimal(1, ...)	...			
qtde_nao_devolvida_conta_enc...	bigint	...			
valor_nao_devolvida_conta_enc...	decimal(1, ...)	...			
qtde_nao_devolvida_motivos_di...	bigint	...			



Nota explicativa: Embora o Databricks contenha todas as dimensões estruturais de suporte do modelo dimensional (como `dim_tempo`, `dim_regiao` e `dim_perfil_cliente`), optou-se por detalhar acima o dicionário das tabelas principais que sustentam diretamente as análises e as respostas às perguntas de negócio do projeto.

3.2 Modelo Dimensional



4. Pipeline de Dados (Etapa 4.4)

4.1 Organização dos Notebooks

Para deixar o projeto mais organizado e fácil de manter, o fluxo foi dividido em 4 etapas executadas em sequência pelo Databricks Workflows:

1. [01_ingestao_bronze.py](#): Carregamento dos arquivos originais e salvamento dos dados brutos exatamente como vieram, sem alterações (camada de *staging*).
2. [02_transformacao_silver.py](#): Limpeza, correção de formatos (texto e valor monetário e enriquecimento semântico com acréscimo das descrições oficiais do Banco Central.
3. [03_modelagem_gold.py](#): Construção das tabelas do modelo dimensional (fatos e dimensões) e criação das funções para padronizar os formatos brasileiros (moeda, porcentagem e datas).
4. [04_views_consumo.py](#): Geração das visões analíticas de consumo para painéis e relatórios, trazendo os dados tanto em formato numérico simples (para gráficos) quanto já formatados em reais e percentuais.

Scripts (Github):

- [mvp_engenharia_de_dados/Notebooks/mvp003-bronze.ipynb](#)
- [mvp_engenharia_de_dados/Notebooks/mvp004-silver.ipynb](#)
- [mvp_engenharia_de_dados/Notebooks/mvp005-gold.ipynb](#)
- [mvp_engenharia_de_dados/Notebooks/mvp006-analise.ipynb](#)
- Observação (Views - Dashboard): KPIs no [Notebook/mvp006](#), Visões no [Notebook/mvp005](#)

5. Qualidade de Dados (Etapa 4.5)

Durante o tratamento dos dados (Bronze -> Silver -> Gold), foram aplicadas as seguintes melhorias práticas:

- **Formatação de Moeda:** Remoção de pontos e substituição da vírgula pelo ponto decimal para converter os valores de texto para o formato numérico correto.
- **Nomes Claros para Meios de Pagamento:** Substituição de códigos técnicos (como DICT, QRDN ou INIC) pelos nomes oficiais do Banco Central (como *Chave Pix / Manual*, *QR Code Dinâmico* ou *Iniciador de Pagamento*).
- **Ordenação Correta das Idades:** Criação da coluna [ordem_faixa_etaria_pagador](#) para garantir a sequência cronológica correta das idades nos gráficos, evitando a ordem alfabética.
- **Cálculos Precisos:** Uso de casas decimais (* 1.0 e * 100.0) e proteção contra divisão por zero para evitar que as porcentagens fossem arredondadas a zero por erro de cálculo.
- **Apresentação no Padrão brasileiro:** Criação de funções na camada [mvp.gold](#) para exibir os resultados diretamente no formato visual habitual (R\$ 1.234,56, 10,5% e DD/MM/AAAA).


6. Análise de Dados e Resposta às Perguntas de Negócio (Etapa 4.5)

6.1 Resposta à Pergunta 1: Tendência Mensal e Risco do Pix

- **Consultas:** [mvp.gold.vw_tendencia_temporal_risco](#) e [mvp.gold.vw_kpi_topo](#).
- **Resultados:** O montante total movimentado cresceu de forma contínua (+33,87% em relação ao mês anterior). O valor médio de cada transação (*ticket médio*) fixou-se entre


R\$ 420,00 e R\$ 510,00, evidenciando que o Pix passou a ser fortemente utilizado para compras quotidianas de pequeno valor.

- **Dashboard:**



6.2 Resposta à Pergunta 2: Concentração Regional e Balança de Pagamentos

- **Consultas:** [mvp.gold.vw_regional_per_capita](#) e [mvp.gold.vw_balanca_inter_regional](#).
- **Resultados:** A região Sudeste concentrou mais de metade do volume financeiro nacional (57,4%). O Sudeste atuou como receptor líquido de capital, enquanto o Sul destacou-se como emissor líquido. [Posição 08/2026]
- **Dashboard:**




6.3 Resposta à Pergunta 3: Perfil de Uso e Meios de Pagamento

- **Consultas:** [mvp.gold.vw_matriz_relacional_pfpj](#) e [mvp.gold.vw_canal_vs_faixa_etaria](#).
- **Resultados:** As transações P2P lideram em quantidade (>65%), mas as operações envolvendo empresas (B2B e P2B) movimentam valores médios consideravelmente superiores. Jovens (18-34 anos) priorizam QR Codes e chaves Pix; utilizadores com mais



de 60 anos recorrem com maior frequência à inserção manual, transacionando montantes superiores. [Posição 08/2026]

- **Dashboard:**



6.4 Resposta à Pergunta 4: Eficácia do MED e Motivos da Falta de Devolução

- **Consultas:** [mvp.gold.vw_funil_med](#) e [mvp.gold.vw_gargalos_devolucao_med](#).
- **Resultados:** Embora grande parte dos pedidos de devolução por fraude são aceitos, apenas 15% a 22% do capital é efetivamente recuperado. O principal entrave é a insuficiência de saldo na conta recebedora (>78% do valor não recuperado), visto que os infratores esvaziam os fundos de imediato.
- **Dashboard:**



7. Autoavaliação

7.1 Atingimento dos Objetivos

O projeto cumpriu integralmente as metas propostas, estruturando com sucesso as camadas no Databricks, respondendo com rigor às quatro perguntas de negócio e alinhando-se às normas do Banco Central.

7.2 Dificuldades Encontradas

- Correção de divisões no Spark SQL que arredondavam ou cortavam os números para zero.

- Centralização de todas as consultas na camada final (**mvp.gold**) para simplificar o acesso aos dados e evitar pastas repetidas.
- Criação de tabelas e visões que servissem ao mesmo tempo para gráficos (números puros) e para relatórios executivos (valores em reais e percentuais).

7.3 Próximos Passos

- Automatizar a ingestão contínua de novos lotes de dados no Databricks.
- Desenvolver modelos preditivos de Inteligência Artificial para estimar o risco de fraude e a probabilidade de recuperação de valores.
- Implementar testes automatizados de qualidade de dados em cada atualização de pipeline.